인수인계 문서에 대한 비판적 검토

전체적으로는 **현재까지 논의한 방향을 상당히 정확하게 정리한 문서**다. 특히 `Evaluator=SFT / Planner=GRPO`, `oracle=counterfactual reference`, `feature set을 action에 포함`, `GBNF는 prompt token을 추가하는 방식이 아님`이라는 핵심 결론에는 동의한다.

다만 실제 구현 전에 **5가지는 수정하거나 명확히 해두는 것이 좋다.**

---

1. 가장 중요한 수정: Tool의 `scope`까지 Planner가 선택하는 것은 너무 빠르다

현재 문서에는:

```
retrieve(
    view ∈ {global, contextual},
    scope ∈ {cluster, global},
    features[]
)
```

로 되어 있다.

그런데 이것은 Planner에게 사실상:

```
view × scope × feature combination
```

을 동시에 선택하게 만든다.

0.5B GRPO에서 처음부터 이 정도 자유도를 주는 것은 위험하다.

특히 현재 핵심 가설은:

> cluster boundary를 넘어 원본 feature context를 활용하면 새로운 evidence를 얻을 수 있는가?

이므로 초기 V1에서는 **scope를 global로 고정**하고,

```
stop
global_knn
contextual_knn(features)
```

만 먼저 검증하는 편이 더 깔끔하다.

`cluster-scoped contextual`이 실제로 의미 있는 별도 retrieval view라는 근거가 나오면 Stage 2에서 추가하는 것이 좋다.

---

2. `features ⊆ agree ∪ persona-match`는 좋은 constraint지만 "정답 공간"으로 고정하면 안 된다

이 제약은 0.5B를 위한 매우 좋은 action-space reduction이다.

하지만 evaluator의 `agree`가 틀릴 가능성이 0이 아니므로:

```
features ⊆ agree
```

를 절대적인 규칙으로 만들면 evaluator의 오류가 planner의 탐색 공간을 막는다.

따라서 구현적으로는:

```
candidate_features =
    agree ∪ persona_match
```

를 **후보 생성 규칙**으로 사용하는 것이 더 적절하다.

즉 planner에게 "이것만 정답"이라고 가르치는 것이 아니라:

> "현재 state에서 합리적으로 탐색할 후보를 이 범위로 제한한다."

라고 보는 것이 좋다.

---

3. Reward의 `Δmargin`은 좋은 primary reward지만 "최종 확정"이라고 부르기에는 아직 이르다

현재 문서의:

```
R = Δmargin − λ·cost
```

는 V1 reward로 매우 적절하다.

하지만 이것이 실제 AgentRAG의 최종 reward라는 뜻은 아니다.

왜냐하면 `nd` 자체가 이미 AnoLLM embedding space의 distance이고, 이번 프로젝트에서 검증하고 싶은 것은 **원본 feature 기반 alternative retrieval이 새로운 evidence를 제공하는가**이기 때문이다.

따라서 최소한 다음을 별도로 기록해야 한다.

```
Δnd / Δmargin
+
neighbor identity 변화
+
feature-context agreement 변화
+
검색 비용
+
latency
```

그래야 나중에:

> "nd가 좋아졌기 때문에 좋은 retrieval인가?"

와

> "실제로 다른 evidence를 가져왔고 그것이 decision에 기여했는가?"

를 분리해서 분석할 수 있다.

즉 `Δmargin`은 **primary optimization signal**로 유지하되, evidence-related metrics는 evaluation에서 반드시 보조적으로 기록하는 것이 좋다.

---

4. V1~V3의 threshold는 "통과/실패 기준"이라기보다 diagnostic gate로 보는 것이 안전하다

예를 들어:

```
V1: global < 80%
V2: corr < 0.9
V3: state별 oracle 분기
```

는 매우 유용한 heuristic이다.

하지만 이 숫자 자체에 이론적인 근거가 있는 것은 아니다.

특히:

```
corr(nd_contextual, nd_global) = 0.91
```

이라고 해서 contextual을 반드시 제거해야 하는 것은 아니다.

두 방법의 correlation이 높더라도:

```
rare state에서 contextual이 큰 개선
```

을 만들 수 있다.

따라서 V2는:

> "action space가 중복될 가능성이 높은가?"

를 보는 **diagnostic signal**로 표현하는 것이 더 정확하다.

---

5. "GRPO group = action 전수 전개, temperature 무관"은 맞지만 구현 세부사항은 확인 필요

현재 action space가 실제로 10개 정도로 제한된다면:

```
동일 state
→ 가능한 action 전부 실행
→ 각 reward 계산
→ group 구성
```

하는 방식은 매우 합리적이다.

이 경우 일반적인 sampling-based GRPO보다 **counterfactual exhaustive evaluation**에 가깝다.

따라서 temperature가 group diversity를 만드는 핵심 변수가 아니다.

다만 실제 사용하는 GRPO implementation이 반드시 이런 exhaustive candidate group을 그대로 지원하는지는 확인해야 한다.

즉 개념적으로는:

> **"sampling으로 다양한 답을 만들게 하는 GRPO"가 아니라 "가능한 retrieval actions의 outcome을 비교하는 GRPO"**

로 정의하는 것이 현재 프로젝트에 훨씬 정확하다.

최종 판단

인수인계 문서의 방향 자체는 유지하는 것을 권한다.

특히 다음 구조는 그대로 가져가도 된다.

```
Evaluator
  ↓
deterministic evidence interpretation
  ↓
Planner
  ↓
STOP / GLOBAL / CONTEXTUAL + feature set
  ↓
Retrieval environment
  ↓
decision outcome + cost
  ↓
GRPO
```

다만 **첫 실험에서는 scope 선택을 제거하고**, `global vs contextual(feature subset) vs stop`의 세 가지 축만으로 시작하는 것이 가장 안전하다.

그리고 가장 중요한 실험적 질문은:

> **"GRPO가 evaluator의 정답을 맞히는가?"가 아니라, "동일한 검색 환경에서 0.5B planner가 state에 따라 더 좋은 retrieval action을 선택하도록 학습되는가?"**

이다.

이렇게 정의하면 기존 Evaluator GRPO 실패와 Planner GRPO를 명확하게 분리할 수 있다.

Evaluator GRPO 실패: 정답 mapping이 존재하는 classification/rephrasing 문제였다.

Planner GRPO: action의 결과를 실행하기 전에는 알 수 없는 counterfactual decision problem이다.

이 구분이 이번 프로젝트에서 GRPO를 사용하는 가장 중요한 논리적 근거다.