Fraudecom 기술 인수인계 — 현재 문제·버그·실험 항목 (LLM 전달용)

전제: 파이프라인 구조(6 MSA on GKE, NB01→02→03 학습 체계, NB04 forwardRAG)는 알고 있다고 가정. GKE 서빙 코드는 안정화 단계 — 본 문서는 **NB01~04(데이터 생성-학습-검증-forwardRAG)** 중심.

0. 최소 컨텍스트 (개념 4줄)

- **det 모드**: cls = nd(정규화 top-1 거리, `sigmoid((d-P50)/IQR)`, P50=1.448/IQR=0.387) threshold, sufficiency = nd-band [0.3, 0.55) 주입. LLM의 자유 출력은 **what_missing(wm) 1개** — "LLM 출력 key 수 = 검증 불가능한 자유도"라는 원리로 5-key→1-key까지 축소해 온 결과.
- **Selective tool gate**: ambiguous에서만 — expand: `nd∈[0.48,0.60) AND plateau_ratio≤0.142` (오프라인 rule search 검증, good/bad flip 3.2:1) / reroute: `match_type=centroid AND rank2/rank1 score≥0.93`(잠정).
- **confident-skip**: 밴드 밖 케이스는 analyzer LLM 호출 자체를 생략 (det에서 판정 경로 불변 — 실측으로 지표 비트 동일 + latency mean −11.6s 확인).
- **forwardRAG baseline**: `PIPELINE_MODE=forward` + `ANALYZER_TASK=forward` — 3-key {cls, confidence, reasoning} 전수 LLM. agent와 동일 eval set(A/B)으로 비교하는 게 최종 산출 서사.

1. 발견된 문제점 (원인 수준)

1-1. Latency 폭발 (CPU 서빙)

- 근본: e2-standard-2(2 vCPU)에서 **prefill이 compute-bound 지배항** (L4 대비 30–70×; decode는 대역폭 bound 10–20×). 3B Q4 GGUF 단건 이론 25–60s, 실측 ~38s.
- 악화 트리거: **persona z-score 블록을 analyzer 프롬프트에 복원**(train-serve 정합 수정)하면서 프롬프트 +~400tok → 단건 38→68s. 재검색(ambiguous→tool) 시 LLM 2회 → 130s+.
- 완료된 대응: tool gate(재검색 84%→10–12%), confident-skip(밴드 밖 LLM 0회 — 단 현 밴드에서 ambiguous 84%라 skip 이득 16%뿐 → 밴드 재조정과 결합 필요).
- 남은 트랙: **0.5B 전환**(det 모드에서 LLM 역할이 wm 한 문장으로 축소돼 정당화됨; 예상 7–12s, slim-prompt 재학습까지 하면 2–3s), prompt diet, llama-server continuous batching(배치 평가 throughput 2–4×, **단건 latency 개선 아님** — llama-cpp-python 단건 API로는 불가).

1-2. what_missing 편향 (학습 데이터 오염)

- 근본: rejection sampling이 **cls-GT만 검사** — teacher의 boilerplate wm이 통과해 학습 분포의 다수 패턴이 됨. 실측: 학습 jsonl wm 고유율 18.9%, top-1 문장("boundary distance; expand evidence") 점유율 28.2% → student가 암기(서빙 42/50 동일 문장). "feature 인용율 71.8%"는 함정 — 최빈 2·3위가 "within range" 류 **정합 서술**이라 grounding 검사를 통과함.

- 파생: reroute 트리거를 wm 텍스트에서 얻을 수 없음(mismatch 서술 1/84) → **deterministic 신호로 대체 완료** (router의 match_type/score ratio).
- 해결 원리(검증 완료, NB04에서): ① **Deviation Table 조건화 생성**(이탈 계산은 코드, teacher는 테이블 근거 서술만) ② **grounded-z rejection**(ABNORMAL이면 인용 feature 중 실제 |z|≥1 이탈 ≥1개) ③ **confidence 재라벨** (`50+50·tanh(|nd−0.5|·4)`, verifiable) — forward 데이터에서 고유율 18.9→75.8%, top1 28.2→4.6%, conf-|nd−0.5| 상관 0.985. **이 원리를 evaluator wm 재생성(NB01)에 역이식하는 것이 다음 핵심 작업.**

1-3. forwardRAG 재생성 데이터의 잔여 이슈

- NORMAL-conformity 서술 반템플릿화(최빈 3개 합 85/1000, "purchase_value and age within cluster norms…"), numeric 2개(purchase_value/age) 인용 편중 — NORMAL 규칙이 느슨했던 탓. → B-1/2/3 로직 반영됨(§3-4).
- confidence 재라벨은 nd 단조 함수 — 모델이 nd 복사만 학습할 위험은 낮지만(그게 목적), **nd 반대편 정답 레코드**(teacher cls==GT인데 nd-함의 cls≠GT)의 conf 라벨이 왜곡될 수 있음 → F5의 calibration(ECE)로 상한 측정.

1-4. 판정 캘리브레이션

- agent FNR 0.72 vs distance-only 0.48의 주범 = `CLS_ND_THRESHOLD=0.5` 미캘리브레이션. 50샘플 best raw threshold 1.318 → 서빙 nd 스케일로 **0.42** (sigmoid((1.318−1.448)/0.387)).
- nd 스케일 함정: NB 오프라인 nd는 rank-percentile, 서빙 nd는 sigmoid — **상수 이식 시 변환 필수** (gate의 EXPAND_ND_LO/HI도 동일 이슈, §4).

2. 수정해야 할 버그 (확정, 적용만 남음)

위치	버그	수
`evaluation/agent_eval/agent_eval_metrics.py` `calculate_boundary_metrics`	`b_total/nb_total`이 루프 **밖**에서 구(raw 거리) 조건으로 재계산 → `boundary_n=0`인데 `boundary_fraud_n=24` 자기모순	루 `b_` 밖
동일 함수 `has_tool`	trace 매칭 목록에 `mcp_navtive`(서빙 측 오타) 미포함 → boundary_expand_rate 항상 0	`t` "r 교
서빙 config	`TOOL_EXECUTION_MODE=mcp_navtive`(오타)로 미검증 mcp 경로 사용 중	`d` 가 인
retriever (검증 필요)	reroute 6건 중 3건 top1 거리가 소수점까지 동일 — `cluster_ids` 필터 no-op(전체 인덱스 검색으로 새는) 정황	re 인

위치	버그	수
env	`CLS_ND_THRESHOLD` 0.5 → **0.42** 미적용	co ro

3. 실험적으로 확인해야 할 사항 (NB 위치 명시)

3-1. NB01 — wm 재생성 (최우선)

- **위치: Section 9 `generate_training_data()` — Pass 2(GT-aware wm 재생성) 직후.**
- 할 일: NB04의 원리 역이식 — Deviation Table을 teacher 프롬프트에 주입 + grounded-z rejection (ban 확장: "within range", "matches" 류 정합 서술 포함) + dedup cap(⩽2%).
- 확인: `wm_bias_report()` 전후 — 게이트 = 고유율 >40%, top1 점유율 <10%. (forward에서 75.8%/4.6% 달성한 것과 동급이 목표.)
- eval jsonl metadata `test_idx`는 반영됨(재생성분부터 직접 매핑).

3-2. NB02 — 재학습

- **위치: TRAINING_JSONL_PATH 지정 셀 + `to_chatml`.**
- evaluator: 필터/재생성 데이터로 **0.5B** 학습(3B 대비 latency 10배 이득 — wm 품질이 judge 기준 3B의 ~90%면 교체 확정). forward: `_KEEP_KEYS=("cls","confidence","reasoning")` 3-key 타깃, 주입 없음.
- GGUF Q4 변환 경로 동일 유지(Section 14) — 어댑터 구조 바꾸지 말 것. PEFT 버전 고정(과거 0.14.0 vs 0.19.1 불일치로 중국어 출력 버그 전례).

3-3. NB03 — 평가 확장

- **위치: Section A(heuristic) 뒤에 추가 셀, Section C-1(load_rows) 뒤.**
- 신규 지표 2개(셀 제공됨, `nb03_actionability_cell.py`): **wm_actionability**(wm의 gap 방향 서술 ↔ deterministic 신호[misroute/plateau] 일치율 — "planner에 실질 도움" 정의) / **teacher_parity**(같은 입력의 `_teacher` wm 대비 인용 feature Jaccard + 방향 일치율 — teacher 상한 대비 위치. fallback 오염 run에서 Jaccard 0.000으로 재학습 필요 신호를 정확히 냈음).
- judge 고도화: `common/judge.py` rubric에 actionability 축 추가 + deviation/misroute 신호를 judge 입력에 주입.
- 비교 축: det vs llm(ANALYZER_DECISION_MODE), 3B vs 0.5B, agent vs forward.

3-4. NB04 — forward 재생성·학습·A/B

- **위치: F1(FORWARD_TEACHER_RULES)/F3(grounded_ok, 생성 루프)/F5(진단) — B-1/2/3 및 F5는 v2 노트북에 반영 완료.**
  - B-1: NORMAL은 "lowest |z| feature 1-2개를 값과 함께" (케이스별 상이한 feature가 deterministic하게 선택)

    - B-2: NORMAL도 grounded 검증(인용 feature가 실제 [ok]) + categorical 유도
    - B-3: 생성 루프 온라인 dedup cap(키당 목표의 2%)
- 순서: F5로 기존 데이터 진단(A-1 cls별/A-2 calibration/A-3 soft-cap) → B 반영 재생성(첫 100개로 rejection 수율 확인) → NB02 학습 → GKE `PIPELINE_MODE=forward` 서빙 → 동일 eval set으로 agent와 A/B.
- A/B 확인 지표: AUROC/FNR, **LLM 호출량**(forward=100% vs agent=ambiguous만), latency 분포, 서빙 confidence ECE ("평균 회귀" 한계를 재라벨 학습이 교정했는지가 forward 서사의 핵심).

3-5. 공통 — 50+ 샘플 재실행 체크리스트 (버그 fix + threshold 0.42 후)

- agent FNR 0.72 → ~0.48(distance-only 수준) 회복 여부
- skip 비율(밴드 밖), expand/reroute 발동률, boundary 지표 정상화(자기모순 해소)
- reroute 실효성: verdict change의 방향별 분해, rank2 cluster의 GT 일치 비율

4. 기타 진행 항목 (2~3 밖, README·종합계획 기준)

- **reroute τ 캘리브레이션**: 게이트 상수 0.93은 관측 중앙값일 뿐 미검증. round_log의 `gate_ratio` × `_gt_cluster≠primary_cluster_id`(misroute) 상관을 다음 배치에서 측정해 τ 확정 — score ratio에 misroute 예측력이 없으면 match_type 단독 조건으로 후퇴.
- **EXPAND_ND_LO/HI 서빙 스케일 환산**: rule search의 [0.48, 0.60)은 rank-percentile — raw 분위수 `np.quantile(d5[:,0], [0.48, 0.60])` → `sigmoid((q-P50)/IQR)`로 환산해 env 교체 (3줄 스니펫 보유).
- **sufficiency 밴드 재조정 A/B**: 현 [0.3, 0.55)는 nd 분포의 84%를 삼킴 → threshold 0.42 중심으로 좁혀 confident-skip 이득 극대화 + LLM 호출률 30~40%대 목표. 단 밴드는 학습 시 주입 기준이므로 wm 재학습과 같은 사이클에서 변경.
- **centered PatchCore reweight (보류 재검토)**: 단순 reweight는 NO-GO(할인 전용 → FNR 폭증), centered(w/E[w], E[w]_k5=0.8612)는 FNR 안전하나 전면 적용 시 효과 소실(+0.5%p) — **expand gate 통과 케이스에만** 적용하는 조합을 마지막에 검토.
- **Graph RAG(장기)**: device/IP 공발생 그래프 신호 — 단일 트랜잭션 임베딩(AnoLLM)이 구조적으로 못 보는 유일한 축. 원본 Fraud_Data.csv(device_id) 필요.
- **시각화(포트폴리오)**: LangGraph mermaid 엔드포인트, Streamlit agent trace 타임라인/latency breakdown, Locust 부하 그래프 — README의 이미지 슬롯 채우기.